

Ôn tập trắc nghiệm Naive Bayes

Tài liệu này tổng hợp kiến thức và các câu trắc nghiệm Naive Bayes đã trao đổi. Nội dung chỉ tập trung vào lý thuyết, công thức và cách suy luận; không bao gồm bài thực hành hoặc mã nguồn notebook.

Contents

1	Xác suất cơ bản	3
1.1	Xác suất của một biến cố	3
1.2	Xác suất có điều kiện	3
2	Định lý Bayes	3
2.1	Ví dụ đã giải	4
3	Naive Bayes cho phân tích cảm xúc	4
4	Prior và logprior	4
5	Xác suất của từ và Laplace smoothing	5
6	Log-likelihood của một từ	5
7	Điểm dự đoán của một tweet	6
8	Thủ tục xây dựng mô hình	6
9	Kiểm tra mô hình Naive Bayes	7
10	Ứng dụng và giới hạn	7
11	Đáp án các câu trắc nghiệm đã giải	8
11.1	Câu 1 — Xác suất chọn người hạnh phúc	8
11.2	Câu 2 — Xác suất có điều kiện	8
11.3	Câu 5 — Áp dụng định lý Bayes	8
11.4	Câu 6 — Dấu của log-likelihood	8
11.5	Câu về miền giá trị của log tỷ lệ	8
11.6	Câu 8 — Thủ tục thực hiện Naive Bayes	9
11.7	Câu 9 — Thành phần cần để kiểm tra mô hình	9

11.8 Câu 10 – Nội dung không phải ứng dụng của Naive Bayes	9
12 Bảng công thức cần nhớ	9
13 Câu hỏi tự kiểm tra	9
14 Ghi nhớ nhanh	10

1. Xác suất cơ bản

1.1. Xác suất của một biến cố

Nếu các kết quả có khả năng xảy ra như nhau:

$$P(A) = \frac{\text{số kết quả thuận lợi cho } A}{\text{tổng số kết quả có thể xảy ra}}.$$

Ví dụ: trong phòng có bốn người A, B, C và D. A và B hạnh phúc; C và D không hạnh phúc. Khi chọn ngẫu nhiên một người:

$$P(\text{hạnh phúc}) = \frac{2}{4} = \frac{1}{2}.$$

1.2. Xác suất có điều kiện

Xác suất của biến cố A khi đã biết B xảy ra:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}.$$

Thông tin điều kiện làm thu hẹp không gian mẫu. Nếu đã biết người được chọn thuộc nhóm hạnh phúc, ta chỉ còn hai khả năng A và B:

$$P(B | \text{hạnh phúc}) = \frac{1}{2}.$$

Điểm dễ nhầm: không tiếp tục chia cho tổng số người ban đầu sau khi đã có điều kiện.

2. Định lý Bayes

Định lý Bayes:

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}.$$

Trong phân tích cảm xúc:

$$P(pos | w) = \frac{P(w | pos)P(pos)}{P(w)}.$$

Các thành phần:

- $P(pos)$: xác suất tiên nghiệm, hay *prior*, của lớp tích cực.
- $P(w | pos)$: *likelihood*, xác suất gặp từ w trong lớp tích cực.
- $P(w)$: xác suất từ w xuất hiện trong toàn bộ dữ liệu.
- $P(pos | w)$: *posterior*, xác suất tweet tích cực sau khi quan sát từ w .

2.1. Ví dụ đã giải

Cho:

$$P(happy | pos) = 0.25, \quad P(happy) = 0.13, \quad P(pos) = 0.40.$$

Khi quan sát từ happy:

$$\begin{aligned} P(pos | happy) &= \frac{P(happy | pos)P(pos)}{P(happy)} \\ &= \frac{0.25 \times 0.40}{0.13} \\ &= 0.76923 \dots \end{aligned}$$

Làm tròn đến hai chữ số thập phân:

$$P(pos | happy) = 0.77.$$

3. Naive Bayes cho phân tích cảm xúc

Naive Bayes dự đoán lớp của một tweet dựa trên:

1. Mức phổ biến ban đầu của mỗi lớp.
2. Mức độ mỗi từ nghiêng về lớp tích cực hoặc tiêu cực.

Với tweet gồm các từ $w_1, w_2, \dots, w_n$, giả định “naive” xem các từ độc lập có điều kiện khi đã biết lớp:

$$P(w_1, w_2, \dots, w_n | pos) \approx \prod_{i=1}^n P(w_i | pos).$$

Tương tự cho lớp tiêu cực:

$$P(w_1, w_2, \dots, w_n | neg) \approx \prod_{i=1}^n P(w_i | neg).$$

Đây là giả định đơn giản hóa. Trong ngôn ngữ tự nhiên, các từ không thực sự độc lập, nhưng mô hình vẫn có thể hoạt động tốt trong nhiều bài toán phân loại văn bản.

4. Prior và logprior

Nếu tập huấn luyện có D_{pos} tweet tích cực và D_{neg} tweet tiêu cực:

$$P(pos) = \frac{D_{pos}}{D_{pos} + D_{neg}}, \quad P(neg) = \frac{D_{neg}}{D_{pos} + D_{neg}}.$$

Logprior được tính bởi:

$$\text{logprior} = \log \frac{P(pos)}{P(neg)} = \log \frac{D_{pos}}{D_{neg}}.$$

Giá trị logprior	Ý nghĩa
> 0	Dữ liệu ban đầu nghiêng về lớp tích cực.
$= 0$	Hai lớp cân bằng.
< 0	Dữ liệu ban đầu nghiêng về lớp tiêu cực.

5. Xác suất của từ và Laplace smoothing

Ký hiệu:

- $\text{freq}(w, pos)$: số lần từ w xuất hiện trong tweet tích cực.
- $\text{freq}(w, neg)$: số lần từ w xuất hiện trong tweet tiêu cực.
- N_{pos} : tổng số lần xuất hiện của mọi từ trong lớp tích cực.
- N_{neg} : tổng số lần xuất hiện của mọi từ trong lớp tiêu cực.
- V : số từ khác nhau trong từ vựng.

Nếu không làm tròn, một từ chưa từng xuất hiện trong một lớp sẽ có xác suất bằng 0. Khi nhân các xác suất, chỉ một thừa số bằng 0 cũng làm toàn bộ tích bằng 0.

Laplace smoothing cộng 1 vào tần suất:

$$P(w | pos) = \frac{\text{freq}(w, pos) + 1}{N_{pos} + V},$$

$$P(w | neg) = \frac{\text{freq}(w, neg) + 1}{N_{neg} + V}.$$

Lợi ích chính:

- Tránh xác suất bằng 0.
- Đảm bảo log của xác suất được xác định.
- Cho phép mô hình xử lý từ chưa xuất hiện trong một lớp.

6. Log-likelihood của một từ

Log-likelihood ratio của từ w :

$$\lambda(w) = \log \left(\frac{P(w | pos)}{P(w | neg)} \right).$$

Điều kiện	$\lambda(w)$	Kết luận
$P(w pos) > P(w neg)$	Dương	Từ nghiêng về tích cực.
$P(w pos) = P(w neg)$	0	Từ trung tính đối với hai lớp.
$P(w pos) < P(w neg)$	Âm	Từ nghiêng về tiêu cực.

Vì tỷ lệ hai xác suất có thể tiến rất gần 0 hoặc tăng rất lớn, log của tỷ lệ không bị giới hạn trong một đoạn hữu hạn:

$$\lambda(w) \in (-\infty, +\infty).$$

Laplace smoothing giúp các xác suất khác 0, nhưng không tạo ra một giới hạn cố định cho log-likelihood.

7. Điểm dự đoán của một tweet

Với tweet gồm các từ $w_1, w_2, \dots, w_n$, điểm Naive Bayes là:

$$p = \text{logprior} + \sum_{i=1}^n \lambda(w_i).$$

Điểm p	Dự đoán
$p > 0$	Tích cực, nhãn 1
$p < 0$	Tiêu cực, nhãn 0
$p = 0$	Hai lớp có bằng chứng ngang nhau

Điểm p là một **log-odds score**, không phải xác suất trực tiếp trong khoảng từ 0 đến 1.

8. Thứ tự xây dựng mô hình

Thứ tự được dùng trong câu trắc nghiệm:

1. Thu thập hoặc gán nhãn dữ liệu thành tweet tích cực và tiêu cực.
2. Tiền xử lý các tweet.
3. Tính tần suất $\text{freq}(w, \text{class})$.
4. Tính $P(w | pos)$ và $P(w | neg)$.
5. Tính $\lambda(w)$.
6. Tính

$$\text{logprior} = \log \frac{P(pos)}{P(neg)}.$$

Quan hệ phụ thuộc cần nhớ:

- Phải tiền xử lý trước khi thống kê các token.

- Phải có tần suất trước khi tính xác suất có điều kiện của từ.
- Phải có hai xác suất có điều kiện trước khi tính log-likelihood ratio.
- Logprior chỉ phụ thuộc số tài liệu mỗi lớp nên về mặt tính toán có thể được tính sớm hơn; trong phương án trắc nghiệm đã xem, nó được đặt ở bước cuối.

9. Kiểm tra mô hình Naive Bayes

Để kiểm tra mô hình, cần:

- X_{val} : các tweet dùng để đánh giá.
- Y_{val} : nhãn thật của các tweet đó.
- λ : log-likelihood của các từ đã học được.
- logprior: log của tỷ lệ prior giữa hai lớp.

Luồng đánh giá:

1. Tính điểm p cho từng tweet trong X_{val} .
2. Chuyển điểm thành nhãn dự đoán bằng ngưỡng 0.
3. So sánh nhãn dự đoán với Y_{val} .
4. Tính độ chính xác:

$$\text{accuracy} = \frac{\text{số tweet được phân loại đúng}}{\text{tổng số tweet}}.$$

Nếu không có Y_{val} , ta có thể tạo dự đoán nhưng không thể tính độ chính xác.

10. Ứng dụng và giới hạn

Naive Bayes phù hợp với các bài toán phân loại như:

- Phân tích cảm xúc.
- Nhận dạng tác giả.
- Phân loại hoặc truy xuất tài liệu.
- Phân giải nghĩa của từ dựa trên ngữ cảnh.
- Lọc thư rác.

Dự đoán một giá trị số liên tục không phải ứng dụng trực tiếp của Naive Bayes chuẩn, vì đó là bài toán hồi quy chứ không phải phân loại.

Các giới hạn quan trọng:

- Giả định các từ độc lập có điều kiện thường không hoàn toàn đúng.
- Mô hình dựa nhiều vào tần suất tương đối trong tập huấn luyện.
- Phù định, mĩa mai, cụm từ cố định và phụ thuộc giữa các từ có thể làm mô hình dự đoán sai.
- Mất cân bằng lớp ảnh hưởng đến prior và có thể làm mô hình thiên lệch.

11. Đáp án các câu trắc nghiệm đã giải

11.1. Câu 1 – Xác suất chọn người hạnh phúc

Có hai người hạnh phúc trong tổng số bốn người:

$$P(\text{hạnh phúc}) = \frac{2}{4} = \boxed{\frac{1}{2}}.$$

Đáp án: 1/2.

11.2. Câu 2 – Xác suất có điều kiện

Khi đã biết người được chọn thuộc nhóm hạnh phúc, không gian mẫu chỉ còn A và B:

$$P(B \mid \text{hạnh phúc}) = \boxed{\frac{1}{2}}.$$

Đáp án: 1/2.

11.3. Câu 5 – Áp dụng định lý Bayes

$$P(\text{pos} \mid \text{happy}) = \frac{0.25 \times 0.40}{0.13} \approx 0.769.$$

Đáp án: 0.77 sau khi làm tròn đến hai chữ số thập phân.

11.4. Câu 6 – Dấu của log-likelihood

$$\lambda(w) = \log \frac{P(w \mid \text{pos})}{P(w \mid \text{neg})}.$$

Số dương cho biết từ nghiêng về tích cực; số âm cho biết từ nghiêng về tiêu cực.

Đáp án: Phương án 1 và 3.

11.5. Câu về miền giá trị của log tỷ lệ

$$\log \frac{P(w \mid \text{pos})}{P(w \mid \text{neg})} \in \boxed{(-\infty, +\infty)}.$$

Đáp án: Từ âm vô hạn đến dương vô hạn.

11.6. Câu 8 – Thủ tục thực hiện Naive Bayes

Đáp án: Gán nhãn → tiền xử lý → tần suất → xác suất theo lớp → log-likelihood → logprior.

11.7. Câu 9 – Thành phần cần để kiểm tra mô hình

$$X_{val}, Y_{val}, \lambda, \text{logprior}.$$

Đáp án: Phương án 1.

11.8. Câu 10 – Nội dung không phải ứng dụng của Naive Bayes

Naive Bayes chuẩn là mô hình phân loại, không phải mô hình hồi quy cho giá trị liên tục.

Đáp án: Dự đoán số, tức phương án 5.

12. Bảng công thức cần nhớ

Khái niệm	Công thức
Xác suất có điều kiện	$P(A B) = P(A \cap B) / P(B)$
Định lý Bayes	$P(A B) = P(B A)P(A) / P(B)$
Xác suất từ trong lớp tích cực	$P(w pos) = (\text{freq}(w, pos) + 1) / (N_{pos} + V)$
Xác suất từ trong lớp tiêu cực	$P(w neg) = (\text{freq}(w, neg) + 1) / (N_{neg} + V)$
Log-likelihood của từ	$\lambda(w) = \log(P(w pos) / P(w neg))$
Logprior	$\text{logprior} = \log(P(pos) / P(neg))$
Điểm của tweet	$p = \text{logprior} + \sum_i \lambda(w_i)$
Quy tắc dự đoán	$p > 0 \Rightarrow pos; p < 0 \Rightarrow neg$
Độ chính xác	$\text{accuracy} = \text{số dự đoán đúng} / \text{tổng số mẫu}$

13. Câu hỏi tự kiểm tra

- Điều kiện đã biết làm thay đổi không gian mẫu như thế nào?
- Trong định lý Bayes, prior và posterior khác nhau ở điểm nào?
- Vì sao phải dùng Laplace smoothing?
- Một từ có $\lambda(w) > 0$ nghiêng về lớp nào?
- Khi $P(w | pos) = P(w | neg)$, $\lambda(w)$ bằng bao nhiêu?
- Log-likelihood ratio có miền giá trị nào?
- Điểm tweet bằng -4 được phân loại vào lớp nào?
- Vì sao cần nhân thật Y_{val} khi kiểm tra mô hình?

9. Vì sao dự đoán giá trị số liên tục không phải ứng dụng trực tiếp của Naive Bayes chuẩn?
10. Giả định “naive” trong Naive Bayes là gì?

Đáp án tự kiểm tra

1. Nó thu hẹp không gian mẫu xuống các trường hợp thỏa mãn điều kiện.
2. Prior là niềm tin trước khi quan sát dữ liệu mới; posterior là xác suất sau khi quan sát bằng chứng.
3. Để tránh xác suất bằng 0 và bảo đảm phép tính log được xác định.
4. Lớp tích cực.
5. Bằng 0.
6. Từ âm vô hạn đến dương vô hạn.
7. Lớp tiêu cực.
8. Để so sánh dự đoán với đáp án đúng và tính độ chính xác.
9. Vì Naive Bayes chuẩn phân loại vào các lớp rời rạc, không dự đoán một đại lượng liên tục.
10. Các đặc trưng hoặc từ được gán định độc lập có điều kiện khi đã biết lớp.

14. Ghi nhớ nhanh

- **Bayes:** đảo chiều xác suất có điều kiện bằng prior và likelihood.
- **Laplace smoothing:** cộng 1 để tránh xác suất bằng 0.
- **Log-likelihood dương:** từ nghiêng về tích cực.
- **Log-likelihood âm:** từ nghiêng về tiêu cực.
- **Điểm tweet dương:** dự đoán tích cực.
- **Điểm tweet âm:** dự đoán tiêu cực.
- **Miền của log-likelihood:** $(-\infty, +\infty)$.
- **Kiểm tra mô hình cần:** dữ liệu, nhãn thật, log-likelihood và logprior.
- **Naive Bayes chuẩn:** dùng để phân loại, không phải dự đoán số liên tục.