

Ôn tập trắc nghiệm Vector Space Models

Tài liệu này tổng hợp kiến thức và 10 câu trắc nghiệm về mô hình không gian vectơ. Nội dung tập trung vào lý thuyết, công thức và cách suy luận; không bao gồm phần thực hành hoặc mã nguồn notebook.

Contents

1	Bức tranh tổng quát	3
2	Khoảng cách Euclid	3
2.1	Hạn chế khi so sánh tài liệu	3
3	Cosine similarity	4
4	Euclid và cosine: khi nào dùng?	4
5	Phép loại suy bằng vectơ từ	5
5.1	Ví dụ USA–Washington–Ankara	5
6	PCA và giảm chiều dữ liệu	6
6.1	Eigenvectors và eigenvalues	6
6.2	Chuẩn hóa dữ liệu	6
7	Thủ tục thực hiện PCA	6
8	Ứng dụng của mô hình không gian vectơ	7
9	Đáp án 10 câu trắc nghiệm	7
9.1	Câu 1 – Tính khoảng cách Euclid	7
9.2	Câu 2 – Chọn tài liệu gần truy vấn	8
9.3	Câu 3 – Phát biểu đúng về khoảng cách Euclid	8
9.4	Câu 4 – Miền của cosine với vectơ không âm	8
9.5	Câu 5 – Tính cosine similarity	9
9.6	Câu 6 – Ankara là thủ đô của quốc gia nào?	9
9.7	Câu 7 – PCA được dùng để làm gì?	9
9.8	Câu 8 – Các phát biểu đúng về PCA	9
9.9	Câu 9 – Thủ tục tính PCA	10

9.10 Câu 10 – Khả năng của mô hình không gian vectơ	10
10 Bảng đáp án nhanh	10
11 Bảng công thức cần nhớ	10
12 Câu hỏi tự kiểm tra	11
13 Ghi nhớ nhanh	11

1. Bức tranh tổng quát

Mô hình không gian vectơ biểu diễn từ, câu hoặc tài liệu bằng các điểm trong một không gian nhiều chiều. Mỗi đối tượng được mô tả bởi một vectơ:

$$\mathbf{x} = \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix}^T.$$

Tùy cách xây dựng, mỗi chiều có thể biểu diễn:

- Tần suất của một từ trong tài liệu.
- Trọng số TF-IDF.
- Một đặc trưng ngữ nghĩa đã học được.
- Một chiều trong word embedding.

Khi đã có vectơ, ta có thể:

- So sánh mức độ giống nhau giữa hai từ hoặc tài liệu.
- Tìm đối tượng gần nhất với một truy vấn.
- Thực hiện phép loại suy ngữ nghĩa.
- Giảm số chiều để trực quan hóa dữ liệu.

2. Khoảng cách Euclid

Với hai vectơ $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$, khoảng cách Euclid là:

$$d(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|_2 = \sqrt{\sum_{i=1}^n (u_i - v_i)^2}.$$

Đây là **chuẩn của hiệu hai vectơ**, không phải bình phương của chuẩn. Bình phương khoảng cách Euclid là:

$$d^2(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|_2^2 = \sum_{i=1}^n (u_i - v_i)^2.$$

Các tính chất cơ bản:

- $d(\mathbf{u}, \mathbf{v}) \geq 0$.
- $d(\mathbf{u}, \mathbf{v}) = 0$ khi và chỉ khi $\mathbf{u} = \mathbf{v}$.
- $d(\mathbf{u}, \mathbf{v}) = d(\mathbf{v}, \mathbf{u})$.
- Khoảng cách nhỏ hơn thường biểu thị hai điểm gần nhau hơn.

2.1. Hạn chế khi so sánh tài liệu

Khoảng cách Euclid nhạy với độ lớn của vectơ. Hai tài liệu có nội dung phân bố tương tự nhưng độ dài rất khác nhau có thể có khoảng cách Euclid lớn vì tài liệu dài thường tạo vectơ có độ lớn lớn hơn.

Khi hướng của vectơ quan trọng hơn độ lớn, cosine similarity thường phù hợp hơn.

3. Cosine similarity

Độ tương đồng cosine đo cosine của góc giữa hai vectơ:

$$\text{cos_sim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2}.$$

Trong đó:

$$\mathbf{u} \cdot \mathbf{v} = \sum_{i=1}^n u_i v_i.$$

Miền giá trị tổng quát:

$$-1 \leq \text{cos_sim}(\mathbf{u}, \mathbf{v}) \leq 1.$$

Cosine	Ý nghĩa hình học
Gần 1	Hai vectơ gần cùng hướng.
Gần 0	Hai vectơ gần vuông góc.
Gần -1	Hai vectơ gần ngược hướng.

Trong truy xuất thông tin, các vectơ đếm từ hoặc TF-IDF thường không âm. Khi đó góc giữa chúng nằm từ 0° đến 90° và:

$$0 \leq \text{cos_sim}(\mathbf{u}, \mathbf{v}) \leq 1.$$

Cosine similarity gần như không đổi khi một vectơ được nhân với một hằng số dương. Vì vậy, nó ít nhạy với độ dài tài liệu hơn khoảng cách Euclid.

4. Euclid và cosine: khi nào dùng?

Tiêu chí	Euclidean distance	Cosine similarity
Đo lường	Khoảng cách giữa hai điểm	Góc hoặc hướng giữa hai vectơ
Giá trị tốt hơn	Nhỏ hơn	Lớn hơn
Nhạy với độ lớn	Có	Ít hơn
Tài liệu dài khác nhau	Có thể hoạt động kém	Thường phù hợp hơn
Miền giá trị	$[0, +\infty)$	$[-1, 1]$, hoặc $[0, 1]$ với vectơ không âm

Hai đại lượng này trả lời hai câu hỏi khác nhau:

- Euclid: hai điểm cách nhau bao xa?
- Cosine: hai vectơ hướng giống nhau đến mức nào?

5. Phép loại suy bằng vectơ từ

Word embeddings có thể mã hóa các quan hệ ngữ nghĩa dưới dạng hiệu vectơ. Ví dụ kinh điển:

$$\text{king} - \text{man} + \text{woman} \approx \text{queen}.$$

Với quan hệ quốc gia-thủ đô:

$$\text{country}_1 - \text{capital}_1 \approx \text{country}_2 - \text{capital}_2.$$

Nếu biết $(\text{capital}_1, \text{country}_1)$ và thủ đô capital_2 , ta ước lượng vectơ của quốc gia thứ hai:

$$\mathbf{v} = \text{country}_1 - \text{capital}_1 + \text{capital}_2.$$

Sau đó so sánh $\mathbf{v}$ với các vectơ quốc gia bằng cosine similarity. Quốc gia có cosine lớn nhất là dự đoán tốt nhất.

5.1. Ví dụ USA-Washington-Ankara

Cho:

$$\text{USA} = \begin{bmatrix} 5 \\ 6 \end{bmatrix}, \quad \text{Washington} = \begin{bmatrix} 10 \\ 5 \end{bmatrix}, \quad \text{Ankara} = \begin{bmatrix} 9 \\ 1 \end{bmatrix}.$$

Vectơ quốc gia cần tìm:

$$\begin{aligned} \mathbf{v} &= \text{USA} - \text{Washington} + \text{Ankara} \\ &= \begin{bmatrix} 5 \\ 6 \end{bmatrix} - \begin{bmatrix} 10 \\ 5 \end{bmatrix} + \begin{bmatrix} 9 \\ 1 \end{bmatrix} \\ &= \begin{bmatrix} 4 \\ 2 \end{bmatrix}. \end{aligned}$$

Các ứng viên:

$$\text{Turkey} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}, \quad \text{Russia} = \begin{bmatrix} 5 \\ 5 \end{bmatrix}, \quad \text{Japan} = \begin{bmatrix} 4 \\ 3 \end{bmatrix}.$$

So sánh cosine:

$$\cos_sim(\mathbf{v}, \text{Turkey}) = \frac{14}{\sqrt{20}\sqrt{10}} \approx 0.9899,$$

$$\cos_sim(\mathbf{v}, \text{Japan}) = \frac{22}{\sqrt{20} \cdot 5} \approx 0.9839,$$

$$\cos_sim(\mathbf{v}, \text{Russia}) = \frac{30}{\sqrt{20}\sqrt{50}} \approx 0.9487.$$

Turkey có cosine lớn nhất, nên Ankara được ghép với Thổ Nhĩ Kỳ.

6. PCA và giảm chiều dữ liệu

Principal Component Analysis (PCA) biến đổi dữ liệu nhiều chiều sang một không gian có ít chiều hơn trong khi cố gắng giữ lại nhiều phương sai nhất có thể.

PCA thường được dùng để:

- Giảm số chiều dữ liệu.
- Nén biểu diễn.
- Loại bỏ phần dư thừa giữa các đặc trưng tương quan.
- Trực quan hóa word vectors trong hai hoặc ba chiều.

PCA không tự gán nhãn và không phải bản thân một mô hình dự đoán.

6.1. Eigenvectors và eigenvalues

PCA tìm các hướng chính của dữ liệu:

- **Eigenvectors** xác định các trục hoặc hướng thành phần chính.
- **Eigenvalues** cho biết lượng phương sai được giữ lại theo từng hướng.

Các thành phần chính trực giao với nhau. Khi chiếu dữ liệu lên các hướng này, các đặc trưng mới không tương quan tuyến tính với nhau.

Nếu sắp xếp:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n,$$

thì tỷ lệ phương sai được giải thích bởi thành phần i là:

$$\frac{\lambda_i}{\sum_{j=1}^n \lambda_j}.$$

6.2. Chuẩn hóa dữ liệu

Trước PCA, cần trừ trung bình của từng đặc trưng:

$$X_{centered} = X - \mu.$$

Nếu các đặc trưng có đơn vị hoặc thang đo rất khác nhau, thường cần chuẩn hóa thêm về độ lệch chuẩn. Nếu không, đặc trưng có độ lớn lớn có thể chi phối các thành phần chính.

7. Thứ tự thực hiện PCA

Quy trình cơ bản:

1. Chuẩn hóa trung bình hoặc mean-center dữ liệu:

$$X_{centered} = X - \mu.$$

2. Tính ma trận hiệp phương sai:

$$\Sigma = \frac{1}{m} X_{centered}^T X_{centered}.$$

3. Phân rã Σ bằng SVD hoặc eigendecomposition:

$$\Sigma = U S U^T.$$

4. Sắp xếp các thành phần theo eigenvalue giảm dần.

5. Chọn k cột đầu của U :

$$U_{reduce} = U[:, 1 : k].$$

6. Chiếu dữ liệu vào không gian mới:

$$X_{reduced} = X_{centered} U_{reduce}.$$

Nếu cần xấp xỉ lại dữ liệu ở không gian ban đầu:

$$X_{approx} = X_{reduced} U_{reduce}^T + \mu.$$

Ma trận hiệp phương sai là thành phần quan trọng vì nó mô tả mức độ các đặc trưng biến thiên cùng nhau.

8. Ứng dụng của mô hình không gian vectơ

Mô hình không gian vectơ cho phép:

- Biểu diễn từ và tài liệu dưới dạng vectơ.
- Tạo các biểu diễn trong đó những đối tượng có ý nghĩa tương tự nằm gần nhau.
- Truy xuất thông tin và tìm kiếm ngữ nghĩa.
- Dịch máy và ánh xạ giữa các không gian ngôn ngữ.
- Xây dựng các hệ thống hỏi đáp và chatbot.
- Phân cụm, phân loại và trực quan hóa dữ liệu ngôn ngữ.

Việc biểu diễn bằng vectơ không tự động bảo đảm mọi thuật toán sẽ được huấn luyện nhanh hơn. Tốc độ còn phụ thuộc số chiều, mô hình, thuật toán tối ưu và kích thước dữ liệu.

9. Đáp án 10 câu trắc nghiệm

9.1. Câu 1 – Tính khoảng cách Euclid

Cho:

$$\mathbf{A} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 4 \\ 7 \\ 2 \end{bmatrix}.$$

$$\begin{aligned}
 d(\mathbf{A}, \mathbf{B}) &= \sqrt{(1-4)^2 + (2-7)^2 + (3-2)^2} \\
 &= \sqrt{9 + 25 + 1} \\
 &= \sqrt{35} \\
 &\approx 5.91608.
 \end{aligned}$$

Đáp án: Phương án 1 – 5.91608.

9.2. Câu 2 – Chọn tài liệu gần truy vấn

Với:

$$\mathbf{C} = \begin{bmatrix} 3 \\ 1 \\ 4 \end{bmatrix},$$

ta có:

$$d(\mathbf{C}, \mathbf{A}) = \sqrt{(3-1)^2 + (1-2)^2 + (4-3)^2} = \sqrt{6} \approx 2.45,$$

$$d(\mathbf{C}, \mathbf{B}) = \sqrt{(3-4)^2 + (1-7)^2 + (4-2)^2} = \sqrt{41} \approx 6.40.$$

Vì $\sqrt{6} < \sqrt{41}$, tài liệu A gần C hơn.

Đáp án: Tài liệu A.

9.3. Câu 3 – Phát biểu đúng về khoảng cách Euclid

Khoảng cách Euclid là chuẩn của hiệu hai vectơ. Nó có thể hoạt động kém khi so sánh các tài liệu có độ dài rất khác nhau. Phương pháp sử dụng góc là cosine similarity; còn bình phương chuẩn chỉ là squared Euclidean distance.

Đáp án: Phương án 1 và 2.

9.4. Câu 4 – Miền của cosine với vectơ không âm

Trong truy xuất thông tin, các vectơ thường không âm, nên:

$$0 \leq s \leq 1.$$

Đáp án: Phương án 3.

9.5. Câu 5 – Tính cosine similarity

Cho:

$$\mathbf{A} = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 2 \\ 8 \\ 1 \end{bmatrix}.$$

Tích vô hướng và chuẩn:

$$\mathbf{A} \cdot \mathbf{B} = 2 - 1 = 1,$$

$$\|\mathbf{A}\| = \sqrt{2}, \quad \|\mathbf{B}\| = \sqrt{69}.$$

Do đó:

$$\cos_sim(\mathbf{A}, \mathbf{B}) = \frac{1}{\sqrt{2}\sqrt{69}} = \frac{1}{\sqrt{138}} \approx 0.0851256531.$$

Đáp án: Phương án 1 – 0.08512565307587486.

9.6. Câu 6 – Ankara là thủ đô của quốc gia nào?

Từ phép loại suy:

$$\text{USA} - \text{Washington} + \text{Ankara} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}.$$

Cosine với Turkey xấp xỉ 0.9899, lớn hơn cosine với Japan và Russia.

Đáp án: Thổ Nhĩ Kỳ, phương án 4.

9.7. Câu 7 – PCA được dùng để làm gì?

PCA được dùng để giảm số chiều và trực quan hóa word vectors. PCA không trực tiếp dự đoán hoặc gán nhãn dữ liệu.

Đáp án: Phương án 1 và 2.

9.8. Câu 8 – Các phát biểu đúng về PCA

Eigenvectors xác định các hướng đặc trưng mới không tương quan; eigenvalues cho biết lượng phương sai hoặc thông tin được giữ lại; ma trận hiệp phương sai là thành phần quan trọng. Khi đặc trưng có thang đo khác nhau, không nên bỏ qua việc chuẩn hóa.

Đáp án: Phương án 1, 2 và 4.

9.9. Câu 9 – Thủ tục tính PCA

Thủ tục đúng là mean normalization, tính ma trận hiệp phương sai Σ , thực hiện SVD, chọn một tập con các cột của U , rồi chiếu X lên các thành phần đã chọn.

Đáp án: Phương án 1.

9.10. Câu 10 – Khả năng của mô hình không gian vectơ

Mô hình không gian vectơ biểu diễn từ và tài liệu bằng vectơ, hỗ trợ nhiều ứng dụng NLP và tạo ra các biểu diễn có quan hệ ngữ nghĩa. Nó không tự động làm mọi thuật toán huấn luyện nhanh hơn.

Đáp án: Phương án 1, 2 và 3.

10. Bảng đáp án nhanh

Câu	Đáp án	Ý chính
1	Phương án 1	Khoảng cách bằng $\sqrt{35} \approx 5.91608$.
2	Tài liệu A	$d(C, A) < d(C, B)$.
3	Phương án 1, 2	Euclid là chuẩn của hiệu và nhạy với độ dài.
4	Phương án 3	Vectơ không âm cho cosine trong $[0, 1]$.
5	Phương án 1	Cosine bằng $1/\sqrt{138}$.
6	Phương án 4	Turkey có cosine lớn nhất với vectơ loại suy.
7	Phương án 1, 2	PCA giảm chiều và hỗ trợ trực quan hóa.
8	Phương án 1, 2, 4	Eigenvectors, eigenvalues và covariance.
9	Phương án 1	Center $\rightarrow$ covariance $\rightarrow$ SVD $\rightarrow$ projection.
10	Phương án 1, 2, 3	Biểu diễn vectơ, ứng dụng NLP và ngữ nghĩa.

11. Bảng công thức cần nhớ

Khái niệm	Công thức
Tích vô hướng	$\mathbf{u} \cdot \mathbf{v} = \sum_i u_i v_i$
Chuẩn Euclid	$\ \mathbf{u}\ _2 = \sqrt{\sum_i u_i^2}$
Khoảng cách Euclid	$d(\mathbf{u}, \mathbf{v}) = \ \mathbf{u} - \mathbf{v}\ _2$
Cosine similarity	$\text{cos_sim}(\mathbf{u}, \mathbf{v}) = (\mathbf{u} \cdot \mathbf{v}) / (\ \mathbf{u}\ \ \mathbf{v}\)$
Phép loại suy	$\mathbf{v} = \text{country}_1 - \text{capital}_1 + \text{capital}_2$
Mean centering	$X_{\text{centered}} = X - \mu$
Covariance	$\Sigma = (1/m) X_{\text{centered}}^T X_{\text{centered}}$
SVD của covariance	$\Sigma = U S U^T$
Chiếu PCA	$X_{\text{reduced}} = X_{\text{centered}} U_{\text{reduce}}$
Tỷ lệ phương sai thành phần i	$\lambda_i / \sum_j \lambda_j$

12. Câu hỏi tự kiểm tra

1. Khoảng cách Euclid là chuẩn hay bình phương chuẩn của hiệu hai vectơ?
2. Vì sao Euclidean distance có thể hoạt động kém với tài liệu dài ngắn khác nhau?
3. Cosine similarity đo độ lớn hay hướng của hai vectơ?
4. Miền tổng quát của cosine similarity là gì?
5. Vì sao cosine của các vectơ đếm từ không âm nằm trong $[0, 1]$?
6. Công thức tìm quốc gia thứ hai từ một cặp quốc gia–thủ đô là gì?
7. PCA giữ lại loại thông tin nào nhiều nhất?
8. Eigenvectors và eigenvalues có vai trò gì trong PCA?
9. Vì sao phải mean-center dữ liệu trước PCA?
10. Sau khi chọn U_{reduce} , dữ liệu được chiếu sang không gian mới như thế nào?

Đáp án tự kiểm tra

1. Là chuẩn của hiệu: $\|\mathbf{u} - \mathbf{v}\|_2$.
2. Vì Euclid nhạy với độ lớn của vectơ, mà độ lớn thường tăng theo độ dài tài liệu.
3. Đo hướng hoặc góc giữa hai vectơ.
4. Từ -1 đến 1 .
5. Vì tích vô hướng không âm nên góc nằm từ 0° đến 90° .
6. $\text{country}_1 - \text{capital}_1 + \text{capital}_2$.
7. Phương sai của dữ liệu.
8. Eigenvectors là hướng chính; eigenvalues là phương sai được giữ lại theo các hướng đó.
9. Để covariance và các thành phần chính mô tả biến thiên quanh trung tâm dữ liệu.
10. $X_{reduced} = X_{centered}U_{reduce}$.

13. Ghi nhớ nhanh

- **Euclid**: đo khoảng cách; nhỏ hơn nghĩa là gần hơn.
- **Cosine**: đo hướng; lớn hơn nghĩa là tương tự hơn.
- **Tài liệu dài khác nhau**: thường ưu tiên cosine hơn Euclid.
- **Cosine tổng quát**: $[-1, 1]$; với vectơ không âm: $[0, 1]$.
- **Loại suy**: cộng và trừ các vectơ biểu diễn quan hệ ngữ nghĩa.
- **PCA**: giảm chiều nhưng cố giữ nhiều phương sai nhất.
- **Eigenvector**: hướng chính; **eigenvalue**: lượng phương sai.
- **Quy trình PCA**: center $\rightarrow$ covariance $\rightarrow$ SVD/eigen $\rightarrow$ chọn thành phần $\rightarrow$ chiếu.